

Elektrotehnički fakultet Univerziteta u Beogradu

Neuralne mreže (13S053NM)

Prvi projektni zadatak – izveštaj

Uvod

Problem koji se rešava jeste klasifikovanje 7 različitih vrsta automobila. Radi se sa trening i test skupovima, od kojih je 3352 odbiraka u training skupu, a 813 u test skupu.

Broj odbiraka Audi klase: 814

Broj odbiraka Hyundai Creta klase: 271

Broj odbiraka Mahindra Scorpio klase: 316


Broj odbiraka Rolls Royce klase: 311

Broj odbiraka Swift klase: 424


Broj odbiraka Tata Safari klase: 441

Broj odbiraka Toyora Innova klase: 775

Podaci su zadovoljavajuće balansirani što je prikazano na grafiku:



Primeri podataka svake od 7 klasa:



Obrada podataka

Za augmentaciju ulaznih podataka izvršeno je rotiranje, flipovanje i uvećanje.

Arhitektura kreiranog modela sastoji se iz 3 konvoluciona sloja i 3 max pooling sloja. U prvom konvolucionom sloju nalaze se 448 parametara, u drugom 4640, a u trećem 18496. Korišćen je dropout za regularizaciju i sprečavanje od preobučavanja.

Ispis u konzoli:

Model: "sequential_1"

Layer (type)	Output Shape	Param #
=====		
sequential (Sequential)	(None, 64, 64, 3)	0
rescaling (Rescaling)	(None, 64, 64, 3)	0
conv2d (Conv2D)	(None, 64, 64, 16)	448
max_pooling2d (MaxPooling2D)	(None, 32, 32, 16)	0
)		

conv2d_1 (Conv2D)	(None, 32, 32, 32)	4640
max_pooling2d_1 (MaxPooling 2D)	(None, 16, 16, 32)	0
conv2d_2 (Conv2D)	(None, 16, 16, 64)	18496
max_pooling2d_2 (MaxPooling 2D)	(None, 8, 8, 64)	0
dropout (Dropout)	(None, 8, 8, 64)	0
flatten (Flatten)	(None, 4096)	0
dense (Dense)	(None, 96)	393312
dense_1 (Dense)	(None, 7)	679

=====

Total params: 417,575

Trainable params: 417,575

Non-trainable params: 0

Obučavanje mreže

Za kriterijumsku funkciju korišćena je **sparse categorical cross-entropy**.


Categorical cross-entropy je funkcija koja se koristi za višeklasnu klasifikaciju gde se svakoj klasi dodeljuje jedinstvena celobrojna vrednost od 0 do (broj klasa – 1).

$$\text{Loss} = - \sum_{i=1}^{\text{output size}} y_i \cdot \log \hat{y}_i$$

Razlika između categorical cross-entropy i sparse categorical cross-entropy jeste u tome kako se označavaju klase:

- Kod categorical cross-entropy oznake su kodirane pomoću jedinica: na primer, ako imamo tri klase, dobili bismo [1,0,0], [0,1,0], [0,0,1]
- Kod sparse categorical cross-entropy oznake su kodirane pomoću celih brojeva, [1],[2] i [3] za pomenuti slučaj

Za funkciju aktivacije izabrana je **ReLU** funkcija (piecewise linear function) koja će proslediti ulaz na izlaz direktno ako je pozitivan, u suprotnom, izlaz će biti nula. Postoje različite vrste ReLU funkcija.



Za FC sloj se koristi **Softmax** funkcija, koja pretvara vektor koji je sačinjen od K realnih vrednosti u vektor od K realnih vrednosti koji sumirani daju 1. Ulazne vrednosti mogu biti pozitivne, negativne nula ili veće od 1, ali softmax ih transformiše u vrednosti između 0 i 1, kako bi mogle da se koriste kao verovatnoće.

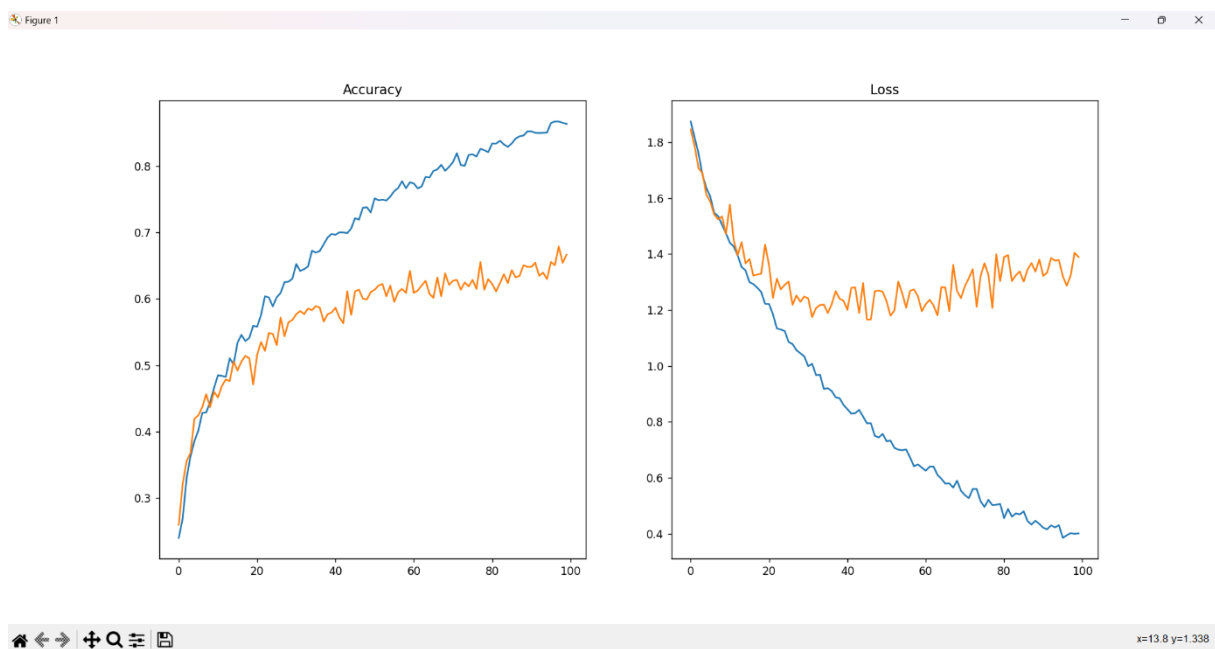
$$\sigma(\vec{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

Preobučavanje

Preobučavanje se dešava kada se model previše dobro obuči na trening skupu. Model teško generalizuje i ne daje dobre rezultate za nove primerke koji se ne nalaze u trening skupu. Konkretno, model prepoznaje konkretne slike iz trening skupa, a ne karakteristike i pattern-e slika skupa.

Za zaštitu od preobučavanja korišćen je **Dropout** sloj, koji u toku treniranja izbacuje ili disable-uje određene neurone u određenoj verovatnoći. Koristi se za sprečavanje preobučavanja i poboljšava performanse.


Grafik performanse:



Tačnost na test skupu: 66,66%

Tačnost na trening skupu: 65,75%

Matrica konfuzije na test skupu:



Matrica konfuzije na trening skupu:



Primeri dobro i loše klasifikovanih primera:

1/1 [=====] - 0s 125ms/step

Predikcija je Rolls Royce, ispravno: Rolls Royce

1/1 [=====] - 0s 19ms/step

Predikcija je Mahindra Scorpio, ispravno: Audi